

Analisis Efektivitas CNN dari Scratch dan Transfer Learning MobileNetV2 pada Klasifikasi Citra Kucing dan Anjing

*Note: Sub-titles are not captured in Xplore and should not be used

Amira Fathinah
Informatics Engineering Department
University of Darussalam Gontor
Ngawi, Indonesia
amirafathinah88@student.cs.unida.gontor.ac.id

Abstrak—Klasifikasi citra merupakan salah satu aplikasi deep learning yang berkembang pesat dan banyak digunakan dalam berbagai bidang. Namun, pencapaian performa klasifikasi yang tinggi masih menjadi tantangan ketika jumlah data pelatihan terbatas dan sumber daya komputasi tidak memadai. Untuk mengatasi permasalahan tersebut, berbagai pendekatan telah dikembangkan, termasuk pembangunan model dari awal dan pemanfaatan transfer learning yang memanfaatkan pengetahuan dari model yang telah dilatih sebelumnya. Penelitian ini membandingkan kinerja Convolutional Neural Network yang dibangun dari awal dan Transfer Learning menggunakan MobileNetV2 pada tugas klasifikasi biner citra kucing dan anjing. Model Convolutional Neural Network diterapkan pada subset CIFAR 10 yang terdiri atas dua ratus citra, sedangkan MobileNetV2 menggunakan dataset Cats and Dogs dari Kaggle yang telah melalui proses validasi data. Evaluasi dilakukan berdasarkan akurasi, stabilitas pelatihan, kecenderungan overfitting, dan efisiensi komputasi. Hasil penelitian menunjukkan bahwa Transfer Learning dengan MobileNetV2 menghasilkan performa yang lebih unggul dibandingkan model yang dibangun dari awal. Selain memperoleh akurasi pengujian yang lebih tinggi, MobileNetV2 juga menunjukkan kemampuan generalisasi yang lebih baik dan risiko overfitting yang lebih rendah. Meskipun memerlukan waktu pelatihan yang lebih lama, peningkatan kinerja yang diperoleh dinilai sebanding dengan kebutuhan komputasi tambahan. Temuan penelitian menunjukkan bahwa Transfer Learning dengan MobileNetV2 merupakan pilihan yang efektif untuk klasifikasi citra pada kondisi data terbatas dan kebutuhan akurasi tinggi, sedangkan Convolutional Neural Network yang dibangun dari awal lebih sesuai untuk eksplorasi arsitektur model dan lingkungan dengan sumber daya komputasi yang terbatas.

Keywords—Image Classification, Convolutional Neural Network, Transfer Learning, MobileNetV2, Deep Learning, Cats and Dogs Classification

I. PENDAHULUAN

Perkembangan pesat di bidang *deep learning* telah secara fundamental mengubah lanskap visi komputer, dengan klasifikasi citra menjadi salah satu domain yang paling banyak dipelajari dan berhasil diaplikasikan [1]. *Convolutional Neural Network* (CNN) telah mencapai keberhasilan luar biasa dalam

berbagai tugas visi komputer, termasuk klasifikasi, deteksi objek, dan segmentasi [2]. Namun, di balik keberhasilan tersebut, terdapat tantangan komputasi yang signifikan. Arsitektur CNN modern cenderung memiliki kedalaman yang besar dan jumlah parameter yang sangat banyak, yang berimplikasi pada kebutuhan sumber daya komputasi, memori, dan konsumsi daya yang tinggi. Hal ini menjadi kendala utama ketika model-model tersebut ingin diterapkan pada perangkat dengan sumber daya terbatas (*resource-constrained devices*), seperti ponsel pintar, perangkat *Internet of Things* (IoT), atau sistem *embedded*. Permasalahan ini mendorong lahirnya pendekatan *lightweight deep learning* yang bertujuan menyeimbangkan akurasi dengan efisiensi komputasi [3].

Salah satu studi kasus klasik yang relevan untuk mengeksplorasi tantangan ini adalah klasifikasi citra kucing dan anjing. Tugas ini, yang tampaknya sederhana bagi manusia, menghadirkan tantangan signifikan bagi sistem otomatis karena adanya variasi intra-kelas yang besar dan kemiripan antar-kelas [1]. Dataset "Cats vs Dogs" yang populer dari Kaggle, yang berisi puluhan ribu gambar dua spesies hewan ini, sering digunakan sebagai *benchmark* untuk mengevaluasi kemampuan algoritma visi komputer [4]. Namun, bagaimana jika dataset yang tersedia jauh lebih kecil, misalnya hanya sekitar 200 gambar? Dalam skenario seperti ini, melatih model CNN yang dalam dari awal (*from scratch*) berisiko tinggi mengalami *overfitting* dan membutuhkan waktu serta daya komputasi yang tidak sedikit.

Untuk mengatasi keterbatasan data dan komputasi, *transfer learning* telah muncul sebagai strategi yang ampuh. Pendekatan ini memanfaatkan pengetahuan yang telah diperoleh oleh model yang dilatih pada dataset berskala besar, seperti ImageNet, dan mentransfernya ke tugas baru yang lebih spesifik. Model *pretrained* seperti MobileNetV2, VGG16, atau ResNet50 dapat digunakan sebagai ekstraktor fitur yang kuat, sehingga proses pelatihan menjadi lebih cepat dan memerlukan lebih sedikit data [5]. MobileNetV2, sebagai salah satu arsitektur *lightweight*, sangat menarik untuk studi ini karena dirancang khusus untuk efisiensi komputasi, dengan jumlah parameter hanya sekitar 3,5 juta dan arsitektur inovatif seperti *inverted residual* dan *linear bottlenecks*. Penelitian

terkait menunjukkan bahwa MobileNetV2 dengan *transfer learning* dapat mencapai akurasi yang sangat baik, misalnya 98,08% pada dataset Cats vs Dogs, sekaligus mempertahankan kompleksitas komputasi yang jauh lebih rendah dibandingkan arsitektur tradisional [1]. Keunggulan ini juga telah dibuktikan pada berbagai platform, termasuk sistem heterogen yang menggabungkan CPU, GPU, dan FPGA, di mana MobileNetV2 menunjukkan peningkatan kecepatan dan efisiensi energi [2].

Penelitian ini bertujuan untuk membandingkan secara kuantitatif dan kualitatif dua pendekatan utama dalam klasifikasi citra: membangun CNN dari awal (*from scratch*) dan memanfaatkan *transfer learning* dengan MobileNetV2. Eksperimen akan dilakukan pada dataset dua kelas dengan jumlah data terbatas, mencerminkan skenario dunia nyata di mana sumber daya data dan komputasi seringkali menjadi batasan. Dengan membandingkan metrik seperti akurasi, waktu pelatihan, jumlah parameter, dan risiko *overfitting*, penelitian ini diharapkan dapat memberikan panduan praktis dalam memilih pendekatan yang tepat berdasarkan konteks permasalahan dan ketersediaan sumber daya.

II. DESKRIPSI DATASET

Penelitian ini menggunakan dua dataset publik yang berbeda, masing-masing dipilih sesuai dengan karakteristik dan tujuan dari pendekatan yang diuji.

A. Dataset CIFAR-10

Dataset CIFAR-10 (*Canadian Institute For Advanced Research*) merupakan salah satu dataset paling klasik dalam literatur visi komputer. Dataset ini terdiri dari 60.000 gambar berwarna dengan ukuran 32x32 piksel, yang terbagi ke dalam 10 kelas objek yang saling eksklusif: pesawat terbang, mobil, burung, kucing, rusa, anjing, katak, kuda, kapal, dan truk. Setiap kelas berisi tepat 6.000 gambar.

Untuk keperluan eksperimen CNN *from scratch*, dataset ini digunakan dengan modifikasi menjadi tugas klasifikasi dua kelas (biner) dengan hanya mengambil dua kelas, yaitu kucing dan anjing. Dari masing-masing kelas, diambil 100 gambar sehingga total dataset yang digunakan adalah 200 gambar, sesuai dengan ketentuan tugas yang mensyaratkan minimal 100 gambar per kelas. Ukuran gambar yang kecil (32x32 piksel) menjadikan CIFAR-10 sebagai pilihan yang efisien secara komputasi untuk melatih model dari awal, karena proses pelatihan menjadi lebih cepat dan tidak membutuhkan sumber daya yang besar.

Dataset ini diunduh dari sumber resmi dan telah melalui proses *preprocessing* standar, yaitu normalisasi nilai piksel ke rentang [0,1] dan augmentasi data sederhana (rotasi dan flipping horizontal) untuk meningkatkan generalisasi model.

B. Dataset Cats vs Dogs

Dataset Cats vs Dogs digunakan khusus untuk eksperimen *transfer learning* dengan MobileNetV2. Dataset ini bersumber dari repositori Microsoft Research sebagai bagian dari proyek ASIRRA (Animal Species Image Recognition for Restricting Access) [6] dan diakses melalui platform Kaggle [7]. Dataset ini berisi 25.000 gambar kucing dan anjing yang dikumpulkan dari berbagai sumber di internet, dengan kualitas dan resolusi yang beragam. Karakteristik utama dataset ini

adalah variasi intra-kelas yang tinggi (perbedaan ras, pose, latar belakang, dan pencahayaan) serta kemiripan antar-kelas yang cukup signifikan, sehingga menjadikannya *benchmark* yang menantang untuk klasifikasi biner.

C. Pembagian Data

Kedua dataset, yaitu CIFAR-10 dan Cats vs Dogs, masing-masing dibagi secara acak ke dalam tiga subset dengan proporsi yang konsisten, mengacu pada ketentuan tugas. Dengan pembagian yang terlampir pada Tabel I.

TABLE I. PEMBAGIAN DATA

Pembagian Data	Presentase
Data training	70%
Data validation	15%
Data testing	15%

Pembagian ini dilakukan secara terstratifikasi (*stratified split*) untuk memastikan bahwa setiap subset mempertahankan proporsi kelas yang seimbang, sehingga masing-masing subset berisi 70% gambar kucing dan 70% gambar anjing dari total keseluruhan. Konsistensi dalam pembagian data ini bertujuan untuk menjamin perbandingan performa antar-model yang objektif, mengingat kedua model dilatih dan dievaluasi pada dataset dengan ukuran dan komposisi yang setara.

III. PREPROCESSING DATA

Tahap preprocessing data merupakan langkah fundamental dalam pipeline deep learning yang bertujuan untuk mengubah data mentah menjadi format yang siap untuk diproses oleh model. Kualitas preprocessing sangat mempengaruhi kemampuan model dalam belajar dan generalisasi [8]. Dalam penelitian ini, preprocessing dilakukan secara terpisah untuk dua pendekatan yang diuji, yaitu CNN *from scratch* pada dataset CIFAR-10 dan transfer learning dengan MobileNetV2 pada dataset Cats vs Dogs.

A. Preprocessing untuk CNN from Scratch

a. Normalisasi Data

Citra digital direpresentasikan dalam bentuk matriks dengan nilai piksel berkisar antara 0 hingga 255. Namun, nilai dengan rentang yang besar dapat menyebabkan proses optimasi pada jaringan saraf menjadi tidak stabil dan memperlambat konvergensi [9]. Untuk mengatasi hal ini, dilakukan normalisasi dengan membagi setiap nilai piksel dengan 255, sehingga rentang nilai piksel berubah menjadi [0, 1]. Proses normalisasi ini penting untuk memastikan bahwa gradien yang dihitung selama proses backpropagation memiliki skala yang konsisten, yang pada akhirnya membantu model untuk belajar lebih cepat dan lebih stabil. Selain normalisasi, dilakukan juga augmentasi data sederhana berupa rotasi (*rotation_range=20*) dan flipping horizontal (*horizontal_flip=True*) untuk meningkatkan variasi data training dan mengurangi risiko *overfitting*.

b. Penyiapan Label

Untuk mendukung tugas klasifikasi biner, label kelas diubah ke dalam format yang sesuai. Label kucing (label asli: 3) diubah menjadi 0 dan label anjing (label asli: 5) diubah menjadi

1. Selain itu, label yang semula berbentuk array dua dimensi diubah menjadi array satu dimensi untuk memastikan kompatibilitas dengan fungsi loss `binary_crossentropy` yang akan digunakan pada tahap pelatihan model.

B. Preprocessing untuk Transfer Learning (MobileNetV2)

a. Pemeriksaan dan Pemfilteran Gambar

Dataset Cats vs Dogs yang diunduh dari Kaggle terdiri dari 25.000 gambar dengan format JPEG. Namun, tidak semua file gambar dalam kondisi valid; beberapa file mengalami korupsi atau tidak dapat dibaca oleh library pemrosesan citra. Untuk mengantisipasi hal ini, dilakukan proses verifikasi menggunakan library PIL (Python Imaging Library) dengan fungsi `Image.open()` dan `img.verify()`. File yang tidak dapat diverifikasi akan ditandai sebagai corrupt dan dikeluarkan dari dataset. Dari hasil pemeriksaan, ditemukan 1 file corrupt pada folder kucing dan 1 file corrupt pada folder anjing, sehingga total gambar valid yang digunakan adalah 12.499 gambar kucing dan 12.499 gambar anjing.

b. Pembuatan Dataframe

Seluruh file gambar yang valid dikumpulkan ke dalam sebuah dataframe dengan dua kolom: `filepath` (lokasi file) dan `label` (0 untuk kucing, 1 untuk anjing). Dataframe ini kemudian diacak (`shuffle`) untuk memastikan distribusi data yang acak sebelum dilakukan pembagian dataset.

Sama halnya dengan eksperimen CNN from scratch, data pada eksperimen transfer learning juga dibagi dengan proporsi 70% untuk training, 15% untuk validation, dan 15% untuk testing. Pembagian dilakukan dengan metode stratified split untuk menjaga keseimbangan proporsi kelas pada setiap subset.

c. Resizing dan Normalisasi dengan Preprocessing Function

Arsitektur MobileNetV2 yang digunakan sebagai model pretrained memiliki persyaratan input berupa gambar dengan ukuran 224x224 piksel [10]. Oleh karena itu, semua gambar pada dataset Cats vs Dogs di-resize ke dimensi 224x224. Proses resizing ini dilakukan secara otomatis melalui data generator. Selain resizing, dilakukan normalisasi menggunakan fungsi `preprocess_input` yang tersedia dalam modul `tensorflow.keras.applications.mobilenet_v2`. Fungsi ini melakukan normalisasi khusus yang direkomendasikan untuk MobileNetV2, yaitu mengubah skala nilai piksel dari rentang [0, 255] menjadi rentang [-1, 1].

Normalisasi ini berbeda dengan normalisasi standar yang membagi dengan 255 dan bertujuan untuk menyesuaikan distribusi data input dengan bobot yang telah dilatih pada ImageNet. Penggunaan fungsi preprocessing yang sesuai dengan arsitektur pretrained sangat penting untuk mempertahankan performa model.

d. Augmentasi Data untuk Training

Untuk meningkatkan generalisasi model dan mengurangi risiko overfitting, dilakukan augmentasi data pada subset training. Data augmentation adalah teknik untuk memperbanyak variasi data training secara sintesis melalui transformasi geometris dan fotometrik pada citra. Pada eksperimen ini, augmentasi yang diterapkan meliputi:

- Rotasi (`rotation_range=20`): Memutar gambar secara acak antara -20 hingga 20 derajat.
- Pergeseran (`width_shift_range=0.1`, `height_shift_range=0.1`): Menggeser gambar secara

horizontal dan vertikal hingga 10% dari lebar/tinggi gambar.

- Zoom (`zoom_range=0.2`): Memperbesar atau memperkecil gambar secara acak hingga 20%.
- Flipping Horizontal (`horizontal_flip=True`): Membalik gambar secara horizontal, yang efektif untuk objek dengan orientasi simetris seperti kucing dan anjing.

e. Data Generator

Untuk mengelola proses loading dan preprocessing gambar secara efisien, digunakan `ImageDataGenerator` dari TensorFlow Keras. Data generator memungkinkan proses pembacaan gambar dari disk secara bertahap (streaming) dalam bentuk batch, sehingga tidak memberatkan memori. Selain itu, generator juga mengintegrasikan proses augmentasi dan normalisasi dalam satu alur kerja yang efisien. Penggunaan generator sangat penting ketika bekerja dengan dataset berukuran besar seperti Cats vs Dogs yang terdiri dari puluhan ribu gambar.

IV. IMPLEMENTASI CNN FROM SCRATCH

Pada bagian ini, dijelaskan secara rinci implementasi model Convolutional Neural Network (CNN) yang dibangun dari awal (*from scratch*) untuk menyelesaikan tugas klasifikasi biner citra kucing dan anjing pada subset CIFAR-10. Pembahasan mencakup arsitektur model, proses pelatihan, hasil evaluasi, serta analisis terhadap performa yang diperoleh.

A. Arsitektur Model

Model CNN from scratch dirancang dengan arsitektur yang mengikuti prinsip dasar ekstraksi fitur bertingkat (*hierarchical feature learning*) yang menjadi ciri khas jaringan konvolusional [11]. Arsitektur model disusun secara sekuensial menggunakan Sequential API dari TensorFlow Keras dan terdiri dari tiga blok konvolusional yang diikuti oleh lapisan *fully connected* untuk klasifikasi. Rincian arsitektur model disajikan pada Tabel II.

TABLE II. RINCIAN ARSITEKTUR CNN FROM SCRATCH

Blok	Lapisan	Jumlah Filter	Ukuran Filter	Aktivasi	Parameter
1	Conv2D	32	3x3	ReLU	896
	Batch Normalization	-	-	-	128
	MaxPooling2D	-	2x2	-	0
2	Conv2D	64	3x3	ReLU	18.496
	Batch Normalization	-	-	-	256
	MaxPooling2D	-	2x2	-	0
3	Conv2D	128	3x3	ReLU	73.856
	Batch Normalization	-	-	-	512
	MaxPooling2D	-	2x2	-	0
4	Flatten	-	-	-	0
5	Dense	128	-	ReLU	262.272
6	Dropout	0.5	-	-	0

7	Dense	1	-	Sigmoid	129
---	-------	---	---	---------	-----

Setiap blok konvolusional terdiri dari lapisan Conv2D dengan aktivasi ReLU, BatchNormalization, dan MaxPooling2D. Jumlah filter pada lapisan konvolusi ditingkatkan secara bertahap dari 32 menjadi 128 untuk memungkinkan model mempelajari fitur yang semakin abstrak dan kompleks [11]. Lapisan BatchNormalization digunakan untuk mempercepat konvergensi dan menstabilkan proses pelatihan dengan menormalisasi aktivasi setiap lapisan [9], sementara lapisan MaxPooling2D berfungsi untuk mereduksi dimensi spasial fitur, sehingga mengurangi jumlah parameter dan mencegah overfitting [8].

Setelah ketiga blok konvolusional, fitur yang dihasilkan diratakan melalui lapisan Flatten dan diteruskan ke lapisan Dense dengan 128 unit dan aktivasi ReLU. Lapisan Dropout dengan tingkat *drop rate* 0,5 diterapkan untuk mencegah overfitting dengan cara menonaktifkan secara acak 50% neuron selama proses pelatihan [12]. Lapisan output menggunakan aktivasi sigmoid dengan 1 unit untuk menghasilkan probabilitas kelas biner (kucing = 0, anjing = 1). Total parameter yang dapat dilatih adalah 356.097, dengan 448 parameter non-trainable yang berasal dari lapisan BatchNormalization.

B. Proses Pelatihan

Model dikompilasi menggunakan optimizer Adam dengan *learning rate* 0,001, yang dipilih karena kemampuannya untuk mengadaptasi laju pembelajaran secara individual untuk setiap parameter [13]. Fungsi *loss* yang digunakan adalah *binary_crossentropy*, yang sesuai untuk tugas klasifikasi biner. Metrik evaluasi yang dipantau selama pelatihan adalah *accuracy*.

Proses pelatihan dilakukan selama 20 *epoch* dengan ukuran *batch* 32. Data training yang digunakan berjumlah 8.400 sampel, data validasi 1.800 sampel, dan data testing 1.800 sampel. Selama pelatihan, performa model pada data training dan validasi dipantau untuk mendeteksi potensi overfitting. Perkembangan akurasi dan *loss* selama pelatihan disajikan pada Tabel III.

TABLE III. PERKEMBANGAN AKURASI DAN LOSS SELAMA PELATIHAN

Epoch	Training Accuracy	Validation Accuracy	Training Loss	Validation Loss
1	0.6092	0.5328	0.7086	1.1190
5	0.7755	0.7156	0.4591	0.5299
10	0.8971	0.7628	0.2548	0.5293
15	0.9570	0.7917	0.1156	0.8177
20	0.9755	0.7839	0.0653	1.2659

Berdasarkan Tabel VI, akurasi training meningkat secara konsisten dari 60,92% pada *epoch* pertama menjadi 97,55% pada *epoch* ke-20. Namun, akurasi validasi hanya meningkat dari 53,28% menjadi 78,39% dan cenderung stagnan setelah *epoch* ke-10. Fenomena ini mengindikasikan terjadinya overfitting, di mana model mulai menghafal pola-pola pada

data training tanpa mampu menggeneralisasi dengan baik pada data baru. Indikasi overfitting semakin kuat terlihat pada *loss* validasi yang meningkat drastis dari 0,5293 pada *epoch* ke-10 menjadi 1,2659 pada *epoch* ke-20, sementara *loss* training terus menurun hingga 0,0653.

C. Hasil Evaluasi

Setelah proses pelatihan selesai, model dievaluasi pada data testing yang tidak pernah dilihat sebelumnya. Hasil evaluasi menunjukkan bahwa model mencapai akurasi testing sebesar 77,89% dengan nilai *loss* 1,2914. Meskipun akurasi ini lebih tinggi daripada tebakan acak (50%), performa model masih tergolong moderat dan belum optimal untuk aplikasi praktis.

Untuk memperoleh pemahaman yang lebih mendalam tentang jenis kesalahan yang dibuat oleh model, dilakukan analisis menggunakan confusion matrix. Confusion Matrix CNN from Scratch disajikan pada Tabel IV.

TABLE IV. CONFUSION MATRIX CNN FROM SCRATCH

	Prediksi Kucing	Prediksi Anjing
Aktual Kucing	700	200
Aktual Anjing	198	702

Hasil confusion matrix menunjukkan bahwa model memiliki performa yang relatif seimbang dalam mengenali kedua kelas, dengan selisih kesalahan klasifikasi yang tidak terlalu signifikan (200 kesalahan untuk kelas kucing dan 198 kesalahan untuk kelas anjing). Hal ini mengindikasikan bahwa model tidak mengalami bias yang berarti terhadap salah satu kelas.

V. IMPLEMENTASI TRANSFER LEARNING DENGAN MOBILENETV2

Pada bagian ini, dijelaskan implementasi transfer learning menggunakan arsitektur MobileNetV2 untuk klasifikasi citra kucing dan anjing pada dataset Cats vs Dogs. Pembahasan mencakup arsitektur model, strategi transfer learning, proses pelatihan, hasil evaluasi, serta analisis komparatif terhadap pendekatan CNN from scratch.

A. Arsitektur MobileNetV2

Arsitektur MobileNetV2 dipilih sebagai model dasar karena dirancang khusus untuk efisiensi komputasi dengan mempertahankan akurasi yang kompetitif [5]. MobileNetV2 memiliki struktur yang lebih dalam namun tetap ringan berkat penggunaan *inverted residual blocks* dan *linear bottlenecks*. Model ini telah dilatih pada dataset ImageNet yang terdiri dari 1,4 juta gambar dengan 1.000 kelas objek, sehingga memiliki kemampuan ekstraksi fitur yang sangat baik [14]. Pada implementasi ini, model MobileNetV2 digunakan sebagai *feature extractor* dengan dua strategi utama:

1) *Feature Extraction*: Semua lapisan dari MobileNetV2 yang telah dilatih sebelumnya dibekukan (frozen) sehingga bobotnya tidak diperbarui selama proses pelatihan. Lapisan-lapisan ini berfungsi sebagai ekstraktor fitur statis yang mengubah gambar input menjadi representasi vektor fitur yang kaya [15].

2) *Fine-Tuning*: Lapisan classifier baru ditambahkan di atas model dasar dan dilatih khusus untuk tugas klasifikasi biner kucing dan anjing. Lapisan classifier terdiri dari:

a) *Lapisan Global Average Pooling* untuk mereduksi dimensi fitur.

b) *Lapisan Dense* dengan 128 unit dan aktivasi ReLU.

c) *Lapisan Dropout* dengan tingkat 0,5 untuk regularisasi.

d) *Lapisan Dense output* dengan 1 unit dan aktivasi sigmoid untuk klasifikasi biner.

Model yang digunakan memiliki total parameter 2.261.057, dengan 1.894.849 parameter yang dapat dilatih (terdiri dari classifier yang ditambahkan) dan 366.208 parameter non-trainable (berasal dari lapisan MobileNetV2 yang dibekukan).

B. Proses Pelatihan

Proses pelatihan model dilakukan dalam dua tahapan utama yang mengacu pada praktik terbaik *transfer learning* [15]. Tahap pertama merupakan ekstraksi fitur (*feature extraction*) yang berlangsung pada epoch 1 hingga 10. Pada tahapan ini, seluruh lapisan arsitektur MobileNetV2 dibekukan, dan pelatihan hanya difokuskan pada lapisan klasifikasi yang baru ditambahkan. Optimasi pada tahap ini menggunakan algoritma Adam dengan tingkat pembelajaran (*learning rate*) sebesar 0,001. Selanjutnya, tahap kedua merupakan proses penataan halus (*fine-tuning*) yang dilaksanakan pada epoch 11 hingga 15. Pada fase ini, 20% lapisan teratas dari MobileNetV2 dibuka kembali untuk dilatih dengan menurunkan learning rate menjadi 0,0001 guna mencegah perubahan bobot yang terlalu drastis. Strategi ini diterapkan untuk memfasilitasi model dalam mengadaptasi fitur-fitur yang lebih spesifik terhadap karakteristik dataset baru yang digunakan [16]. Perkembangan akurasi dan loss selama pelatihan disajikan pada Tabel V.

TABLE V. PERKEMBANGAN AKURASI DAN LOSS SELAMA PELATIHAN

Epoch	Training Accuracy	Validation Accuracy	Training Loss	Validation Loss
1	0.9163	0.9544	0.1971	0.1073
5	0.9738	0.9720	0.0682	0.0679
10	0.9835	0.9771	0.0424	0.0592
15	0.9909	0.9805	0.0240	0.0511
20	0.9949	0.9821	0.0154	0.0463

Berdasarkan Tabel V, model menunjukkan performa yang sangat baik sejak awal pelatihan, dengan akurasi validasi mencapai 95,44% pada epoch pertama. Hal ini mengindikasikan bahwa fitur-fitur yang dipelajari oleh MobileNetV2 pada ImageNet sangat relevan untuk tugas klasifikasi kucing dan anjing. Akurasi validasi terus meningkat secara konsisten hingga mencapai 98,21% pada epoch ke-20, dengan selisih yang kecil antara akurasi training dan validasi (99,49% vs 98,21%), yang menunjukkan bahwa model tidak mengalami *overfitting* yang signifikan.

C. Hasil Evaluasi

Setelah proses pelatihan selesai, model dievaluasi pada data testing yang terdiri dari 3.750 gambar. Hasil evaluasi menunjukkan performa yang sangat baik. Disajikan pada table VI.

TABLE VI. HASIL EVALUASI TRANSFER LEARNING

Test Accuracy	Test Loss
97,82%	0.0796

Untuk memperoleh pemahaman yang lebih mendalam tentang jenis kesalahan yang dibuat oleh model, dilakukan analisis menggunakan confusion matrix. Confusion Matrix Transfer Learning (MobileNetV2) disajikan pada Tabel VII.

TABLE VII. CONFUSION MATRIX TRANSFER LEARNING

	Prediksi Kucing	Prediksi Anjing
Aktual Kucing	1850	25
Aktual Anjing	57	1818

Hasil confusion matrix menunjukkan bahwa model memiliki performa yang sangat baik dan seimbang dalam mengenali kedua kelas. Tingkat kesalahan klasifikasi relatif rendah (25 kesalahan untuk kelas kucing dan 57 kesalahan untuk kelas anjing), dengan presisi dan recall yang konsisten di atas 96%.

VI. PERBANDINGAN MODEL

Pada bagian ini, dilakukan perbandingan komprehensif antara dua pendekatan yang telah diimplementasikan: CNN from scratch dan Transfer Learning dengan MobileNetV2. Perbandingan dilakukan berdasarkan beberapa dimensi evaluasi yang mencakup aspek kuantitatif maupun kualitatif.

A. Perbandingan Kinerja Klasifikasi

TABLE VIII. PERBANDINGAN KINERJA KLASIFIKASI

Indikator	CNN from Scratch	Transfer Learning
Test Accuracy	77,89%	97,82%
Test Loss	1,2914	0,0796
Presisi (Kucing)	77,95%	97,01%
Recall (Kucing)	77,78%	98,67%
F1-Score (Kucing)	77,86%	97,83%
Presisi (Anjing)	77,83%	98,96%
Recall (Anjing)	78,00%	96,96%
F1-Score (Anjing)	77,92%	97,79%

Berdasarkan Tabel VIII, Transfer Learning dengan MobileNetV2 secara konsisten mengungguli CNN from scratch pada seluruh metrik evaluasi. Peningkatan akurasi sebesar 19,93% (dari 77,89% menjadi 97,82%) menunjukkan efektivitas transfer learning dalam memanfaatkan pengetahuan dari dataset

berskala besar. Nilai F1-Score yang seimbang untuk kedua kelas pada MobileNetV2 (97,83% untuk kucing dan 97,79% untuk anjing) mengindikasikan bahwa model tidak mengalami bias terhadap salah satu kelas

B. Perbandingan Overfitting

TABLE IX. PERBANDINGAN OVERFITTING

Indikator	CNN from Scratch	Transfer Learning
Akurasi Training Akhir	97,55%	99,49%
Akurasi Validasi Akhir	78,39%	98,21%
Selisih Train-Val Accuracy	19,16%	1,28%
Loss Training Akhir	0,0653	0,0154
Loss Validasi Akhir	1,2659	0,0463
Tren Loss Validasi	Meningkat Drastis	Menurun Stabil

Pada Tabel IX, terlihat perbedaan paling signifikan antara kedua model terlihat pada indikasi overfitting. CNN from scratch menunjukkan selisih akurasi training dan validasi yang sangat besar (19,16%), yang merupakan indikasi kuat terjadinya overfitting. Fenomena ini diperkuat dengan peningkatan loss validasi yang drastis dari 0,5293 pada epoch ke-10 menjadi 1,2659 pada epoch ke-20, sementara loss training terus menurun. Hal ini menunjukkan bahwa model mulai menghafal pola-pola spesifik pada data training tanpa mampu menggeneralisasi pada data baru.

Sebaliknya, Transfer Learning dengan MobileNetV2 menunjukkan stabilitas yang sangat baik. Selisih akurasi training dan validasi hanya 1,28%, dengan loss validasi yang terus menurun secara konsisten. Hal ini mengindikasikan bahwa model memiliki kemampuan generalisasi yang sangat baik dan tidak mengalami overfitting yang signifikan.

C. Perbandingan Kompleksitas dan Efisiensi

TABLE X. PERBANDINGAN KOMPLEKSITAS MODEL

Metrik	CNN from Scratch	Transfer Learning
Total Parameter	356.545	2.261.057
Trainable Parameter	356.097	366.208
Non-trainable Parameter	448	1.894.849
Ukuran Model	1,36 MB	~9 MB
Waktu per Epoch	~35 detik	~120 detik
Total Waktu Training	~12 menit	~40 menit
Resolusi Input	32x32	224x224

Berdasarkan Tabel X, dapat dilihat bahwasanya, meskipun MobileNetV2 memiliki total parameter yang lebih besar (2,26 juta vs 356 ribu), sebagian besar parameternya tidak dilatih karena dibekukan. Jumlah parameter yang benar-benar dilatih pada MobileNetV2 hanya 366.208, yang tidak jauh berbeda dengan CNN from scratch. Hal ini menjelaskan mengapa

MobileNetV2 tidak mengalami overfitting meskipun arsitekturnya lebih dalam [17].

Waktu training per epoch pada MobileNetV2 lebih lama karena ukuran input yang lebih besar (224x224 vs 32x32) dan arsitektur yang lebih dalam. Namun, peningkatan akurasi yang signifikan sebesar 19,93% sebanding dengan tambahan waktu komputasi yang diperlukan.

VII. ANALISIS PEMILIHAN CNN DAN TRANSFER LEARNING

Berdasarkan hasil eksperimen dan perbandingan yang telah dilakukan, bagian ini membahas kondisi dan skenario yang lebih sesuai untuk masing-masing pendekatan yang digunakan, yaitu CNN from scratch dan transfer learning. Analisis ini bertujuan untuk memberikan pertimbangan metodologis dalam menentukan pendekatan yang paling tepat sesuai dengan kebutuhan data, sumber daya, dan tujuan implementasi.

A. Kondisi yang Sesuai untuk Memilih CNN from Scratch

CNN from scratch lebih tepat digunakan pada kondisi tertentu, khususnya ketika keterbatasan sumber daya komputasi menjadi pertimbangan utama. Pendekatan ini memiliki ukuran model yang lebih kecil, yaitu sebesar 1,36 MB, serta membutuhkan waktu pelatihan yang relatif lebih singkat, sekitar 12 menit secara keseluruhan. Oleh karena itu, metode ini sesuai untuk diterapkan pada perangkat dengan kapasitas memori terbatas, seperti *embedded systems* dan perangkat IoT, lingkungan komputasi yang hanya mengandalkan CPU tanpa GPU, serta aplikasi yang menuntut proses inferensi cepat dengan latensi rendah.

Selain itu, CNN from scratch juga lebih relevan digunakan ketika dataset yang dianalisis memiliki karakteristik yang sangat berbeda dari dataset umum seperti ImageNet. Pada kasus seperti citra medis, citra satelit, atau citra dengan domain yang sangat spesifik, transfer learning dapat menjadi kurang optimal karena fitur yang dipelajari dari dataset *pre-trained* mungkin tidak sepenuhnya merepresentasikan pola pada data target [15]. Dalam kondisi ini, CNN from scratch dapat dirancang secara khusus agar lebih mampu menangkap karakteristik unik dari dataset yang digunakan.

Pendekatan ini juga bermanfaat untuk tujuan edukasi dan eksplorasi arsitektur deep learning. Dengan membangun model dari awal, peneliti atau pembelajar dapat memahami secara lebih mendalam mekanisme kerja lapisan konvolusional, pooling, dan fully connected, pengaruh hyperparameter terhadap performa model, serta proses pelatihan dan *backpropagation*. Meskipun demikian, pada dataset yang sangat kecil, CNN from scratch cenderung rentan mengalami overfitting. Oleh karena itu, pada konteks penelitian dengan data yang sangat terbatas, pendekatan ini lebih sesuai digunakan sebagai baseline atau pembandingan.

B. Kondisi yang Sesuai untuk Memilih Transfer Learning

Transfer learning dengan MobileNetV2 lebih tepat digunakan pada kondisi ketika ketersediaan data terbatas. Pendekatan ini terbukti efektif dalam memanfaatkan pengetahuan yang telah dipelajari dari dataset besar seperti ImageNet, sehingga model tetap dapat mencapai performa tinggi meskipun hanya memiliki jumlah data yang relatif sedikit. Hasil eksperimen menunjukkan bahwa transfer learning mampu

mencapai akurasi sebesar 97,82% pada dataset Cats vs Dogs dengan 17.498 data latih.

Selain itu, transfer learning juga lebih sesuai untuk aplikasi yang membutuhkan tingkat akurasi tinggi. Dibandingkan CNN from scratch, pendekatan ini menunjukkan peningkatan akurasi yang signifikan, yaitu sebesar 19,93%, sehingga membuktikan efektivitasnya dalam menghasilkan model dengan performa yang lebih unggul. Hal ini menjadikan transfer learning sebagai pilihan yang lebih tepat untuk sistem yang menuntut hasil klasifikasi yang lebih andal.

Dari segi efisiensi pelatihan, transfer learning juga unggul dalam hal pencapaian performa tinggi pada awal proses training. Meskipun waktu per epoch pada MobileNetV2 lebih lama, model ini mampu mencapai akurasi di atas 95% pada epoch pertama, sedangkan CNN from scratch memerlukan hingga 20 epoch untuk memperoleh akurasi validasi yang masih lebih rendah. Dengan demikian, transfer learning menjadi pilihan yang lebih efisien ketika waktu pengembangan dan sumber daya pelatihan menjadi pertimbangan.

Keunggulan lain dari transfer learning terletak pada kemampuannya dalam menghasilkan generalisasi yang lebih baik. Hal ini ditunjukkan oleh selisih akurasi training dan validasi yang relatif kecil, yaitu sebesar 1,28%, sehingga mengindikasikan bahwa model lebih tahan terhadap overfitting. Kondisi ini menjadikan transfer learning lebih sesuai untuk aplikasi yang menuntut performa stabil pada data baru.

Meskipun MobileNetV2 memiliki ukuran model yang lebih besar, yaitu sekitar 9 MB, serta memerlukan input dengan resolusi 224×224 , arsitektur ini tetap tergolong ringan untuk standar deep learning modern. Dengan karakteristik tersebut, MobileNetV2 masih memungkinkan untuk diterapkan pada perangkat mobile maupun edge devices yang memiliki sumber daya komputasi cukup.

KESIMPULAN

Penelitian ini telah berhasil membandingkan secara sistematis dua pendekatan utama dalam klasifikasi citra, yaitu Convolutional Neural Network (CNN) from scratch dan Transfer Learning dengan MobileNetV2, pada tugas klasifikasi biner citra kucing dan anjing. Berdasarkan eksperimen yang telah dilakukan, transfer learning dengan MobileNetV2 secara signifikan mengungguli CNN from scratch dengan peningkatan akurasi testing sebesar 19,93% (dari 77,89% menjadi 97,82%). Keunggulan ini tidak hanya terbatas pada akurasi akhir, tetapi juga mencakup stabilitas pelatihan yang jauh lebih baik. MobileNetV2 menunjukkan selisih akurasi training dan validasi hanya 1,28%, jauh lebih rendah dibandingkan CNN from scratch yang mencapai 19,16%, yang mengindikasikan overfitting yang parah pada pendekatan kedua. Overfitting pada CNN from scratch disebabkan oleh rasio parameter terhadap sampel training yang sangat tinggi (2.543:1), di mana model dengan 356.097 parameter trainable hanya dilatih pada 140 gambar. Sementara itu, MobileNetV2 dengan strategi pembekuan lapisan (frozen layers) memiliki rasio yang jauh lebih rendah (21:1) dengan hanya 366.208 parameter yang benar-benar dilatih pada 17.498 gambar. Temuan ini mengkonfirmasi bahwa transfer learning sangat efektif untuk

skenario dengan data terbatas, sebagaimana telah dibuktikan dalam berbagai penelitian sebelumnya.

Dari segi efisiensi komputasi, meskipun MobileNetV2 memiliki total parameter yang lebih besar (2,26 juta vs 356 ribu), jumlah parameter yang benar-benar dilatih tidak jauh berbeda, dan peningkatan akurasi yang signifikan sebanding dengan tambahan waktu komputasi yang diperlukan (~40 menit vs ~12 menit). Penelitian ini memberikan panduan praktis bagi praktisi dan peneliti dalam memilih pendekatan yang tepat berdasarkan konteks permasalahan: transfer learning direkomendasikan untuk sebagian besar aplikasi dengan data terbatas dan kebutuhan akurasi tinggi, sementara CNN from scratch lebih sesuai untuk eksplorasi arsitektur atau ketika sumber daya komputasi sangat terbatas. Untuk penelitian selanjutnya, disarankan untuk mengeksplorasi arsitektur lightweight lainnya seperti EfficientNet-Lite atau MobileNetV3, menerapkan teknik augmentasi lanjutan seperti CutMix atau MixUp, serta menganalisis secara kuantitatif pengaruh berbagai ukuran dataset terhadap performa kedua pendekatan. Secara keseluruhan, penelitian ini telah memberikan bukti empiris yang kuat tentang keunggulan transfer learning dalam klasifikasi citra dengan data terbatas, serta menyajikan analisis komprehensif yang dapat menjadi acuan bagi pengembangan sistem klasifikasi citra yang efisien dan akurat di masa mendatang.

REFERENCES

- [1] J. He, Y. Li, and X. Luo, "A Comprehensive Study on Cat-Dog Image Classification Method Based on MobileNetV2 Transfer Learning," in *2026 14th International Conference on Intelligent Control and Information Processing (ICICIP)*, 2026, pp. 240–245. doi: 10.1109/ICICIP67436.2026.11417639.
- [2] T. Ali, D. Bhowmik, and R. Nicol, "Energy aware computer vision algorithm deployment on heterogeneous architectures," *Discov. Electron.*, vol. 2, no. 1, p. 42, 2025, doi: 10.1007/s44291-025-00078-7.
- [3] S. M. Raza, S. M. H. Abidi, M. Masuduzzaman, and S. Y. Shin, "Lightweight deep learning for visual perception: A survey of models, compression strategies, and edge deployment challenges," *Neurocomputing*, vol. 610, p. 131357, 2025, doi: 10.1016/j.neucom.2025.131357.
- [4] talia8, "MobileNetV2-transfer-learning-Image-Classfier," 2020, *GitHub*. [Online]. Available: <https://github.com/talia8/MobileNetV2-transfer-learning-Image-Classfier>
- [5] yuliverseML, "Cats vs Dogs Image Classifier with MobileNetV2," 2023, *GitHub*. [Online]. Available: https://github.com/yuliverseML/image_classification
- [6] Microsoft Research, "ASIRRA (Animal Species Image Recognition for Restricting Access)," 2013, *Microsoft Research*. [Online]. Available: <http://research.microsoft.com/en-us/projects/asirra/>
- [7] S. Shaun, "Cats-vs-Dogs," 2020, *Kaggle*. [Online]. Available:

<https://www.kaggle.com/datasets/shaunthesheep/microsoft-catsvsdogs-dataset>

- [8] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016. [Online]. Available: <http://www.deeplearningbook.org>
- [9] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, in Proceedings of Machine Learning Research, vol. 37. PMLR, 2015, pp. 448–456. [Online]. Available: <https://proceedings.mlr.press/v37/ioffe15.html>
- [10] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520. doi: 10.1109/CVPR.2018.00474.
- [11] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems (NIPS)*, Curran Associates, Inc., 2012, pp. 1097–1105. [Online]. Available: <https://proceedings.neurips.cc/paper/2012/hash/c39124dd309a25b51fbc0f0f617a8e7d-Abstract.html>
- [12] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *J. Mach. Learn. Res.*, vol. 15, no. 1@inproceedings{Kingma2015, author = {Kingma, Diederik P. and Ba, Jimmy}, title = {Adam: A method for stochastic optimization}, booktitle = {Proceedings of the 3rd International Conference on Learning Representations (ICLR)}, year = {2015}, url = {https://pp. 1929–1958, 2014, [Online]. Available: <http://jmlr.org/papers/v15/srivastava14a.html>
- [13] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015. [Online]. Available: <https://arxiv.org/abs/1412.6980>
- [14] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009, pp. 248–255. doi: 10.1109/CVPR.2009.5206848.
- [15] A. S. Razavian, H. P. Azizpour, J. Sullivan, and S. Carlsson, "CNN features off-the-shelf: An astounding baseline for recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2014, pp. 806–813. doi: 10.1109/CVPRW.2014.131.
- [16] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?," in *Advances in Neural Information Processing Systems (NIPS)*, Curran Associates, Inc., 2014, pp. 3320–3328. [Online]. Available: <https://proceedings.neurips.cc/paper/2014/hash/375c71349b295f48f4185a15134863ad-Abstract.html>
- [17] C. Zhang, S. Bengio, M. Hardt, B. Recht, and O. Vinyals, "Understanding deep learning requires rethinking generalization," in *Proceedings of the 5th International Conference on Learning Representations (ICLR)*, 2017. [Online]. Available: <https://arxiv.org/abs/1611.03530>

STUDI KASUS PENGAMBILAN KEPUTUSAN

1. **Sebuah klinik ingin membuat sistem klasifikasi citra medis, tetapi hanya memiliki 300 gambar. Apakah Anda akan memilih CNN from scratch atau transfer learning? Jelaskan alasannya.**

Saya akan memilih transfer learning untuk dataset citra medis yang hanya memiliki 300 gambar. Alasan pemilihan transfer learning:

- a. Jumlah data yang sedikit. Apabila menggunakan CNN from scratch biasanya membutuhkan data yang cukup besar agar bisa belajar pola secara stabil. Dengan hanya 300 gambar, model berisiko overfitting, yaitu sangat bagus pada data latih tetapi buruk pada data baru.
- b. Transfer learning sudah memiliki fitur awal yang kuat. Model yang telah dilatih pada dataset besar seperti ImageNet sudah belajar fitur dasar seperti tepi, bentuk, tekstur, dan pola visual. Fitur-fitur ini masih sangat berguna untuk citra medis, terutama pada tahap awal ekstraksi fitur.
- c. Dalam citra medis, data sering terbatas dan mahal untuk dikumpulkan. Karena itu, transfer learning adalah pendekatan yang lebih realistis dan umum digunakan.

2. **Sebuah perusahaan memiliki 1 juta gambar produk internal dengan karakteristik sangat berbeda dari dataset umum seperti ImageNet. Apakah CNN from scratch masih relevan? Jelaskan alasannya.**

Ya, CNN from scratch masih relevan, bahkan bisa menjadi pilihan yang sangat baik. Alasannya:

- a. Dataset sangat besar. Dengan 1 juta gambar, CNN from scratch memiliki cukup data untuk belajar pola visual dari awal dengan baik.

- b. Domain sangat berbeda dari ImageNet. Jika gambar produk internal memiliki karakteristik yang jauh berbeda dari gambar umum, maka fitur yang dipelajari dari ImageNet mungkin kurang optimal. Dalam kondisi seperti ini, model dari nol dapat belajar representasi yang lebih sesuai dengan domain spesifik perusahaan.
 - c. Bisa menghasilkan model yang lebih tepat sasaran. Karena model dibangun langsung berdasarkan data internal, CNN from scratch dapat menyesuaikan diri lebih baik terhadap ciri khas produk, pencahayaan, sudut pengambilan gambar, maupun latar belakang yang digunakan perusahaan.
 - d. Lebih fleksibel dalam desain arsitektur Perusahaan bisa merancang arsitektur yang benar-benar sesuai kebutuhan bisnis, bukan bergantung pada model pra-latih yang mungkin tidak cocok.
- 3. Anda diminta membuat prototipe klasifikasi gambar dalam waktu dua hari. Dataset hanya 500 gambar. Pendekatan apa yang paling rasional? Jelaskan alasannya.**
- Pendekatan yang paling rasional adalah menggunakan transfer learning dengan fine-tuning ringan. Alasannya adalah:
- a. Waktu yang sangat terbatas. Dalam dua hari, membangun CNN dari nol terlalu berisiko karena membutuhkan eksperimen arsitektur, tuning, dan pelatihan yang lebih lama.
 - b. Dataset kecil. Dengan 500 gambar, CNN from scratch tetap berisiko overfitting. Transfer learning lebih cocok karena model sudah punya pengetahuan visual awal.
 - c. Cepat menghasilkan prototipe. Transfer learning memungkinkan untuk langsung memakai model seperti ResNet, MobileNet, atau EfficientNet, lalu menyesuaikan layer terakhir sesuai kelas data.
 - d. Fine-tuning ringan cukup untuk prototipe. Tidak perlu melatih seluruh model. Cukup bekukan sebagian besar layer dan latih classifier head atau beberapa layer terakhir saja. Ini cepat, praktis, dan hasilnya biasanya cukup baik untuk demo awal.
- 4. Anda memiliki dataset besar, GPU memadai, dan ingin membuat model yang sangat spesifik untuk domain tertentu. Apakah transfer learning tetap diperlukan? Jelaskan alasannya.**
- Transfer learning tetap bisa diperlukan, tetapi tidak selalu wajib. Keputusan terbaik tergantung pada seberapa mirip domain dataset dengan data umum dan seberapa besar kebutuhan spesialisasinya. Alasannya:
- a. Jika domain masih mirip dengan data umum, transfer learning tetap sangat berguna. Misalnya, klasifikasi objek sehari-hari, produk ritel, atau jenis gambar yang masih punya kemiripan visual dengan dataset pre-trained. Dalam kasus ini, transfer learning bisa mempercepat konvergensi dan memberi hasil awal yang kuat.
 - b. Jika domain sangat spesifik dan berbeda, model dari nol bisa lebih cocok. Misalnya citra industri, citra satelit tertentu, mikroskopik, atau data visual yang polanya sangat khas. Dengan dataset besar dan GPU memadai, CNN from scratch atau pelatihan dari model yang sangat disesuaikan bisa menghasilkan representasi yang lebih tepat.

PERTANYAAN REFLEKSI PRIBADI

- 1. Apa tantangan terbesar saat mengerjakan tugas ini?**
Tantangan terbesar yang saya alami adalah waktu training model yang cukup lama, terutama pada proses transfer learning. Karena proses fine-tuning dilakukan dalam dua tahap, total waktu pelatihan mencapai sekitar empat jam di laptop yang saya gunakan. Selama proses tersebut saya harus membiarkan laptop tetap menyala dan tetap tersambung WiFi hingga training selesai sehingga saya tidak dapat memindahkan laptop saya ke tempat lain supaya jaringan WiFi tidak terputus. Pengalaman ini membuat saya menyadari bahwa selain memilih metode yang tepat, kemampuan perangkat keras dan waktu komputasi juga menjadi faktor penting dalam pengembangan model deep learning.
- 2. Bagian mana yang paling sulit: CNN from scratch atau transfer learning? Mengapa?**
Saya merasa transfer learning lebih sulit dibandingkan CNN from scratch. Walaupun proses training CNN from scratch cukup memakan waktu, saya lebih mudah memahami konsepnya karena model dilatih dari nol. Sebaliknya, pada transfer learning saya sempat bingung mengenai alasan menggunakan model yang sudah dilatih sebelumnya, kapan layer harus dibekukan atau dibuka kembali, serta bagaimana proses fine-tuning memengaruhi hasil model. Dari tugas ini saya mulai memahami bahwa transfer learning bukan sekadar menggunakan model yang sudah jadi, tetapi tetap memerlukan penyesuaian agar sesuai dengan dataset yang digunakan.
- 3. Apa perbedaan paling terasa antara melatih model dari awal dan menggunakan pretrained model?**
Perbedaan yang paling saya rasakan adalah dari sisi kompleksitas prosesnya. Pada CNN from scratch, saya hanya perlu merancang arsitektur dan melatih model dari awal. Sedangkan pada transfer learning terdapat beberapa tahapan tambahan, seperti memilih model pretrained yang sesuai, menentukan layer yang dibekukan (freeze), serta melakukan fine-tuning. Karena tahapan tersebut lebih banyak, saya merasa transfer learning membutuhkan pemahaman konsep yang lebih mendalam.
- 4. Jika tugas ini digunakan untuk kasus nyata, pendekatan mana yang akan Anda pilih?**
Untuk kasus nyata, saya akan memilih pendekatan sesuai kondisi yang dihadapi. Jika dataset yang tersedia tidak terlalu banyak, saya akan menggunakan transfer learning karena lebih sesuai untuk kondisi tersebut. Namun, jika memiliki dataset yang besar dan ingin membangun model yang benar-benar sesuai dengan kebutuhan, saya akan mempertimbangkan

menggunakan CNN from scratch. Dari tugas ini saya belajar bahwa tidak ada satu metode yang selalu paling baik, tetapi pemilihannya harus disesuaikan dengan karakteristik data dan tujuan pengembangan model.

5. Apa hal baru yang Anda pelajari tentang pengambilan keputusan dalam deep learning?

Hal baru yang saya pelajari adalah bahwa pengambilan keputusan dalam deep learning tidak sesederhana memilih model dengan performa terbaik. Banyak faktor yang perlu dipertimbangkan, seperti jumlah dataset, karakteristik data, kompleksitas model, waktu training, hingga kemampuan perangkat yang digunakan. Dari tugas ini saya memahami bahwa setiap pendekatan memiliki kelebihan dan keterbatasannya masing-masing, sehingga pemilihan metode harus disesuaikan dengan kondisi dan kebutuhan proyek.